분리비전 AI (Bunri-Vision): 실환경 오염·혼합 생활폐기물 9종 비전 판독 및 한국형 분리배출 의사결정 시스템

> **한 장의 스마트폰 사진으로 구겨지고 오염된 생활폐기물의 재질을 판독하고, 모델 주목 영역(Spatial CAM)과 환경부 『내 손안의 분리배출』 기준 과태료 주의사항까지 실시간 안내하는 자체 학습 딥러닝 비전 웹 서비스**

---

0. 프로젝트 정보

항목	내용
학번	`201935607`
이름	김대현
과목명	가천대학교 기계학습 프로그래밍 (기말고사 대체 포트폴리오 프로젝트)
프로젝트명	분리비전 AI (`Bunri-Vision`)
공개 데모 URL	**https://bunri-vision-30945587032.asia-northeast3.run.app**
GitHub 저장소 URL	**https://github.com/qwertypotter6873/bunri-vision**
학습 가중치 릴리즈	**https://github.com/qwertypotter6873/bunri-vision/releases/tag/v1.0.0**

---

1. 문제 정의

1.1 실생활 문제 상황 정의 (4W)

구분	상세 내용
Who (누가)	원룸·오피스텔에 거주하는 대학생·사회초년생 1인 가구(자취생), 다세대 주택 입주민 및 분리배출 규정이 낯선 외국인 거주자
What (무엇을)	구겨지거나 음식물·흙 등이 묻은 실생활 폐기물 사진을 촬영하면 **9가지 세부 폐기물 범주**(골판지, 음식물류, 유리, 금속, 복합·오염 일반쓰레기, 종이, 플라스틱, 폐의류·섬유, 초목류)를 자동 분류하고, **한국형 수거함 배출 기준·오염 시 종량제 전환 권고·과태료 주의사항**을 즉시 제공
When (언제)	야간이나 퇴근 후 어두운 실내 조명·베란다 분리수거함 앞에서 *"화분에서 죽은 식물 줄기는 음식물인가 일반쓰레기인가?"*, *"젖은 천·오염된 용기는 재활용이 되는가?"* 등 배출 방법을 즉석에서 판단해야 할 때
Why (왜 필요한가)	① 환경부 조사에 따르면 생활계 종량제 봉투 내 재활용 가능 자원이 약 50% 이상 혼입되는 반면, 반대로 분리수거함에는 오염 이물질·복합재질이 섞여 선별장 잔재 폐기물이 급증하고 있음. ② 특히 1인 가구는 **초목류(식물 줄기·뿌리·낙엽)를 음식물쓰레기로 오배출**하거나 **오염된 섬유·일회용기를 재활용함에 배출**하여 지자체 과태료(최대 10~30만 원) 부과 및 수거 거부 문제를 반복적으로 겪음.

1.2 기존 서비스 대비 차별점

비교 기준	환경부 『내 손안의 분리배출』 앱	기존 학술 모델 (TrashNet 기반)	범용 외부 AI API (ChatGPT 등)	분리비전 AI (본 프로젝트)
인식 방식	사용자가 품목명을 직접 텍스트 검색	백색 도화지 위 깨끗한 단일 물체만 인식	외부 상용 멀티모달 API 유료 호출	**자체 학습한 실환경 도메인 특화 비전 모델 직접 추론**
실환경 강건성	시각 판독 기능 없음	구겨짐·그림자·트레이 배경에서 정확도 급락	프롬프트·조명에 따라 응답 일관성 변동	**Shades-of-Gray WB + LAB-CLAHE 조명·대비 자동 보정 탑재**
한국형 오배출 방지	방대한 문서 열람 필요	단순 재질명(Paper/Plastic)만 출력	과태료 예외 규정 할루시네이션 가능	**초목류 vs 음식물 분리 판별 + 오염 동반 확률 복합 경고**
설명가능성·비용	없음 (무료)	히트맵·신뢰도 보정 미제공	호출당 API 비용 발생 및 개인 사진 외부 전송	**단일 ONNX 패스 Spatial CAM 히트맵 + 온도 보정 신뢰도 제공 (무료·33ms)**

1.3 정량 목표 설정 및 달성 요약

클래스 간 최대 **2.90 : 1 불균형**(`Plastic 921장` vs `Textile Trash 318장`)이 존재하는 데이터셋 특성을 반영하여, 다수 클래스 편향 없이 소수 클래스까지 균등하게 평가하는 **Test Macro-F1**을 주 평가지표(Primary Metric)로 설정하였습니다.

평가지표 구분	지표명	프로젝트 정량 목표	최종 모델 달성치	목표 달성 여부
주 평가지표 (Primary)	**Test Macro-F1**	**≥ 0.8800**	**0.9603** (INT8 ONNX: **0.9607**)	**초과 달성 (+0.0803p)**
보조 지표 1	Test Accuracy (Top-1 / Top-2)	≥ 0.8900	**0.9634** / **0.9944**	**초과 달성 (+0.0734p)**
보조 지표 2	Test Macro-AUROC (OvR)	≥ 0.9600	**0.9978**	**초과 달성 (+0.0378p)**
보조 지표 3	확률 보정 오차 (Test ECE ↓)	≤ 0.0300	**0.0093** (보정 전 0.0738)	**초과 달성 (-87.4% 감소)**
서비스 지표	단일 이미지 CPU 추론 지연시간	≤ 150 ms	**32.84 ms** (ONNX Runtime CPU)	**초과 달성 (4.6배 고속)**

---

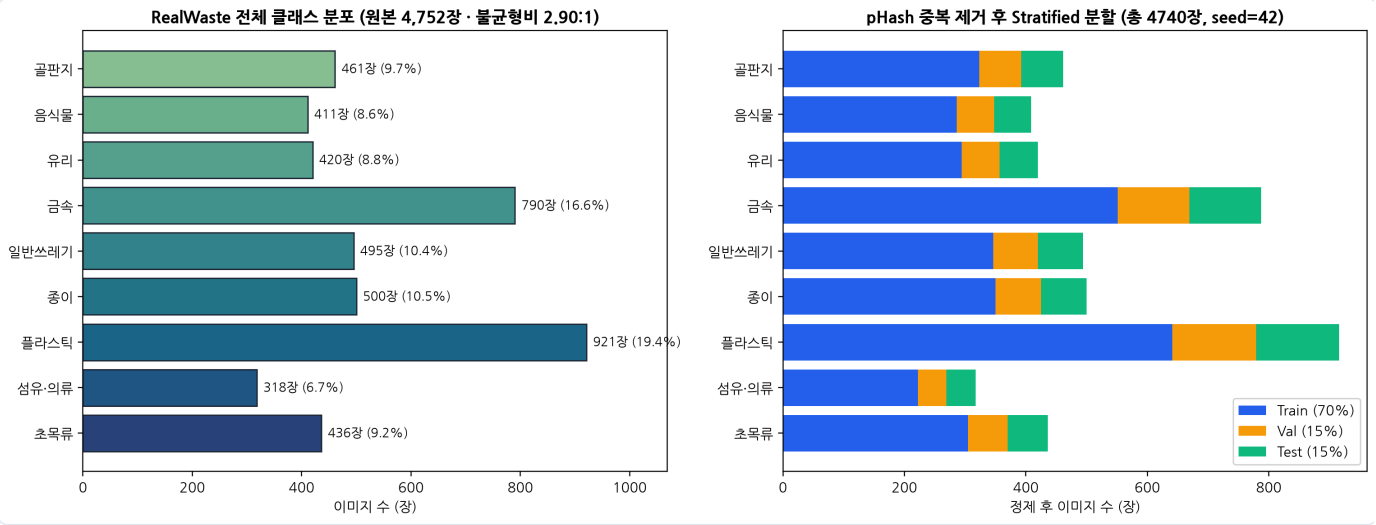
2. 데이터

2.1 데이터 출처, 라이선스 및 기본 제원

- **데이터셋명**: **RealWaste** (*A Novel Real-Life Data Set for Landfill Waste Classification Using Deep Learning*, Single et al., *Information* 2023)
- **공식 출처**: UCI Machine Learning Repository ID #908 (https://archive.ics.uci.edu/dataset/908/realwaste)
- **원시 다운로드 URL**: `https://archive.ics.uci.edu/static/public/908/realwaste.zip` (`scripts/download_data.py` 자동화 구현)
- **라이선스**: UCI 공식 레포지토리 등록 기준 **CC BY 4.0** (원시 아카이브 내 저자 README 기준 **CC BY-NC-SA 4.0** 병기 — 학술·교육 포트폴리오 비상업 목적 및 원저자 출처 표기 완전 준수)
- **전체 규모 및 포맷**: 원본 총 **4,752장** (`524 × 524 px` , 24-bit RGB JPEG, 손상 파일 0장) → 지각 해시(`pHash`) 근접 중복 12장 제거 후 최종 **4,740장**

2.2 9개 클래스 구성 및 분포

번호	영문 클래스명	한국어 매핑 품목	원본 수량 (비율)	정제 후 합계	Train (70%)	Val (15%)	Test (15%)	한국 분리배출 핵심 분류
1	`Cardboard`	골판지·택배 상자	461장 (9.70%)	461장	323	69	69	종이·골판지류 수거함
2	`Food Organics`	음식물류 폐기물	411장 (8.65%)	409장	286	62	61	음식물 전용 종량제/수거함
3	`Glass`	유리병·유리 용기	420장 (8.84%)	420장	294	63	63	유리병류 수거함
4	`Metal`	금속캔·고철류	790장 (16.62%)	787장	551	118	118	캔·고철류 수거함
5	`Miscellaneous Trash`	복합재질·오염 일반 쓰레기	495장 (10.42%)	494장	346	74	74	일반 종량제 봉투
6	`Paper`	일반 종이·인쇄물	500장 (10.52%)	500장	350	75	75	종이류 수거함
7	`Plastic`	플라스틱 용기·페트류	921장 (19.38%)	916장	641	138	137	투명페트 / 플라스틱 수거함
8	`Textile Trash`	폐의류·섬유류	318장 (6.69%)	317장	222	47	48	의류수거함 (오염 시 종량제)
9	`Vegetation`	초목류·식물 잔재물	436장 (9.18%)	436장	305	65	66	**일반 종량제 (음식물 금지)**
합계	**9개 클래스**	**최대 불균형비 2.90 : 1**	**4,752장 (100%)**	**4,740장**	**3,318장**	**711장**	**711장**	**누수 쌍 0건 검증 완료**



2.3 데이터 선정 이유

1. **스튜디오 데이터의 한계 극복 (Real-World Authenticity)**: 널리 쓰이는 `TrashNet` (2,527장) 등은 깨끗하게 펴진 물체를 흰색 배경지 위에서 촬영하여, 실제 가정에서 찍은 찌그러진 캔·흙 묻은 플라스틱·그늘진 사진을 입력하면 배경 변화에 취약합니다. 반면 `RealWaste`는 호주 울런공 실제 자원회수 시설(Whyte's Gully)에서 반입된 찌그러지고 오염된 실물 폐기물을 직접 촬영하여 실생활 일반화 성능 확보에 적합합니다.
2. **한국형 분리배출 핵심 혼동 범주 포함**: 단순 재활용 4~6종 데이터셋과 달리 `Food Organics` (음식물)와 `Vegetation` (초목류), `Textile Trash` (섬유류)와 `Miscellaneous Trash` (복합·오염 일반쓰레기)가 분리 라벨링되어 있어, 자취생이 가장 많이 혼동하는 **초목류 일반쓰레기 판별**과 **오염 폐기물 종량제 전환 판정**을 모델 수준에서 구현할 수 있습니다.

---

3. 데이터 전처리

전체 4,752장을 전수 탐색적 데이터 분석(EDA)한 결과, ① 연속 촬영으로 인한 근접 중복 이미지 쌍(`pHash ≤ 4`) **14쌍**, ② 촬영 시간·조명 차이에 따른 RGB 색편향 지수 상위 5%(`0.1516`)와 하위 5%(`0.0075`) 간 **20배 편차**, ③ 투명 유리·페트병의 낮은 지역 명암 대비(`min Contrast Std = 15.69`), ④ 외곽 10% 영역의 분류 트레이 가장자리 노이즈(`border edge density = 0.1629`)를 확인하고 **4가지 도메인 특화 전처리 기법**을 직접 코드(`src/preprocessing.py` , `src/dataset.py`)로 구현하였습니다.

3.1 구현한 4가지 핵심 전처리 기법

기법 ① 지각 해시(`pHash` , 해밍 거리 ≤ 4) 근접 중복 제거를 통한 데이터 누수 차단

동일 폐기물을 미세하게 회전·연속 촬영한 프레임이 Train과 Test에 동시에 들어가 성능이 과대평가되는 현상을 막기 위해, 64-bit 이산 코사인 변환(DCT) 기반 `pHash` 해밍 거리 `≤ 4` 인 근접 중복 12장(14쌍)을 분할 전에 제거하였습니다.

```
# src/dataset.py — pHash(8x8 DCT) 해밍 거리 <= 4 근접 중복 샘플 탐지 및 제거
ph = imagehash.phash(im, hash_size=8)
dists = np.abs(bits[i + 1:].astype(np.int16) - bits[i].astype(np.int16)).sum(axis=1)
near_idxs = np.where(dists <= phash_dedup_threshold)[0] + (i + 1)  # threshold = 4
```

기법 ② Shades-of-Gray (p=6 민코프스키 노름) 색항등성 화이트밸런스 보정

실내 형광등·백열등이나 야외 그늘의 푸른빛/노란빛 색편향을 완화하면서도 초목류(`Vegetation`) 고유의 녹색 색조가 과보정되지 않도록 채널 게인을 `[0.82, 1.22]` 로 제한한 Shades-of-Gray 조명 정규화를 적용하였습니다.

```
# src/preprocessing.py — Minkowski p=6 Shades-of-Gray 조명 색온도 보정
def shades_of_gray_white_balance(rgb_uint8: np.ndarray, power: float = 6.0) -> np.ndarray:
    arr = rgb_uint8.astype(np.float32) / 255.0
    norm_per_channel = np.power(np.mean(np.power(arr + 1e-6, power), axis=(0, 1)), 1.0 / power)
    scale = np.clip(np.mean(norm_per_channel) / (norm_per_channel + 1e-6), 0.82, 1.22)
    return (np.clip(arr * scale[None, None, :], 0.0, 1.0) * 255.0).round().astype(np.uint8)
```

기법 ③ CIE-LAB 색공간 적응형 히스토그램 평활화 (`Adaptive LAB-CLAHE`)

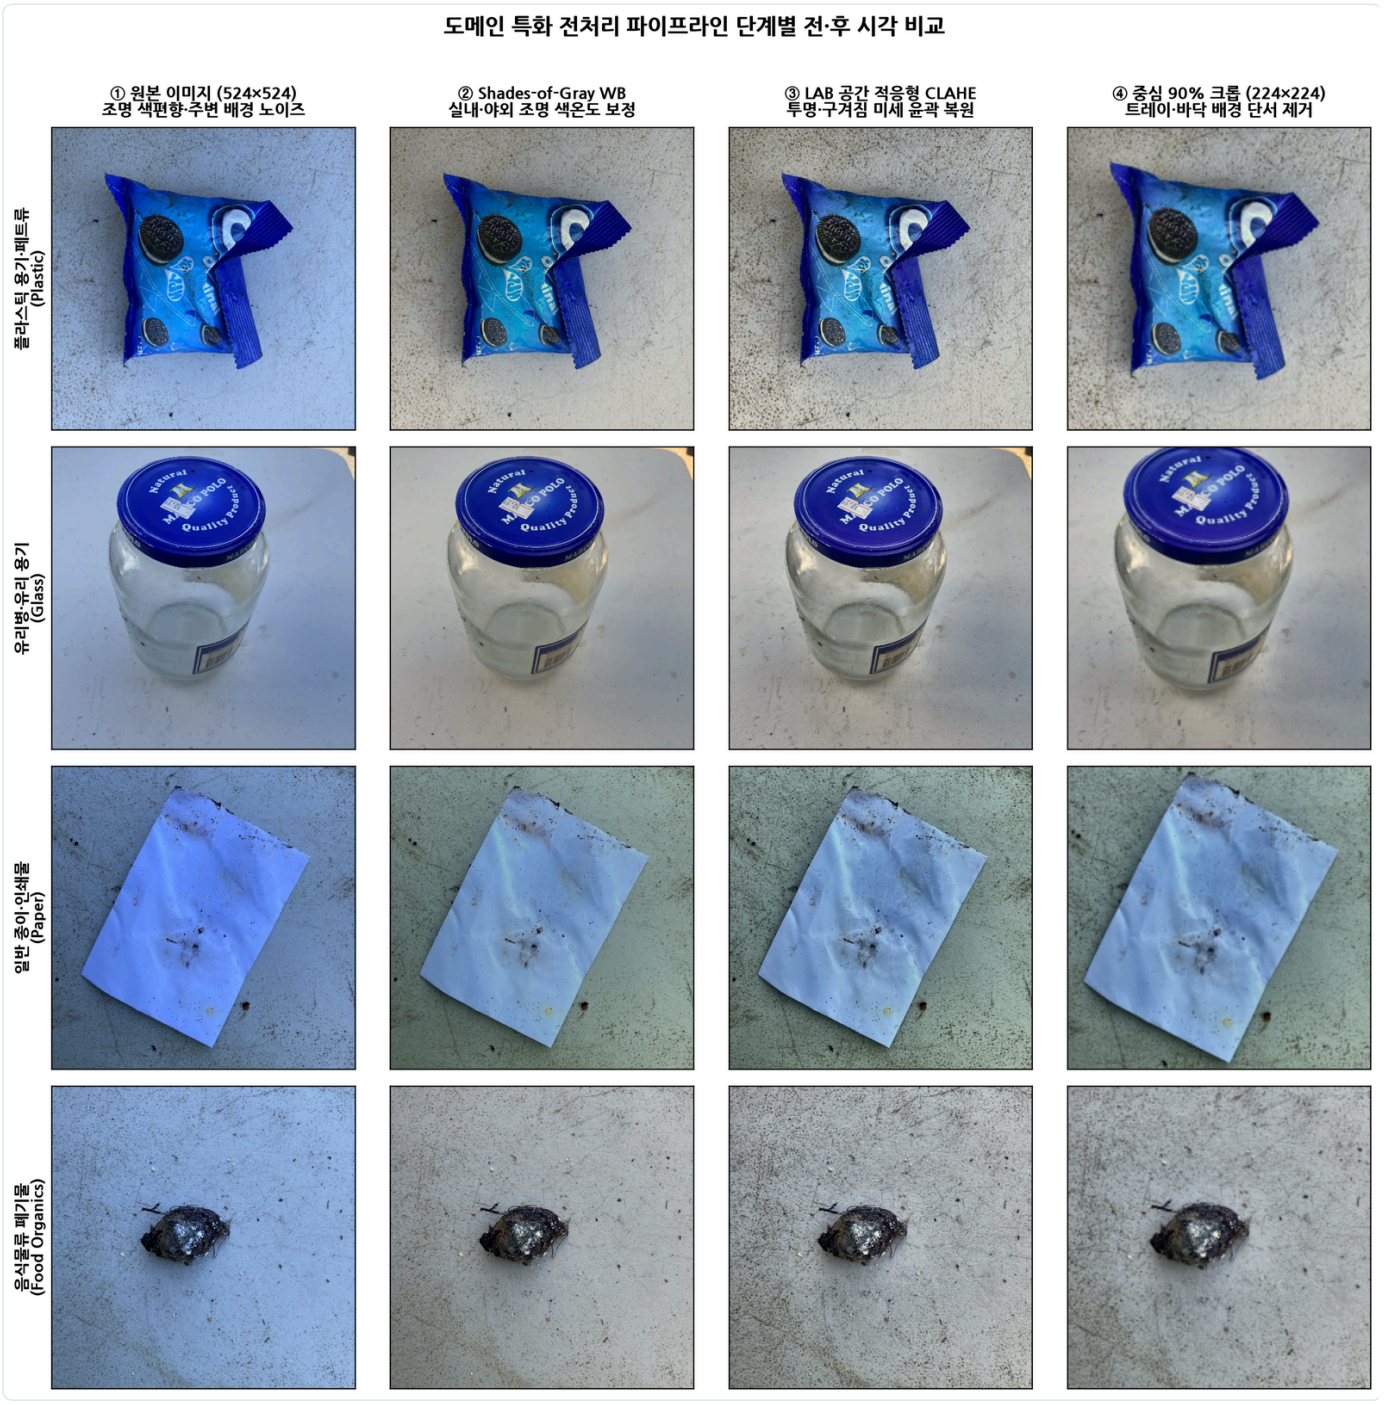
RGB 채널에 직접 히스토그램 평활화를 가하면 재질 고유 색상이 깨지므로, 색차 성분(`A` , `B`)은 보존하고 밝기 성분(`L`)에만 `CLAHE(clipLimit=1.8, tileGridSize=(8,8))` 를 적용 후 원본 `L` 과 `0.65 : 0.35` 로 블렌딩하여 투명 플라스틱·유리·구겨진 종이의 미세 굴곡 윤곽을 복원하였습니다.

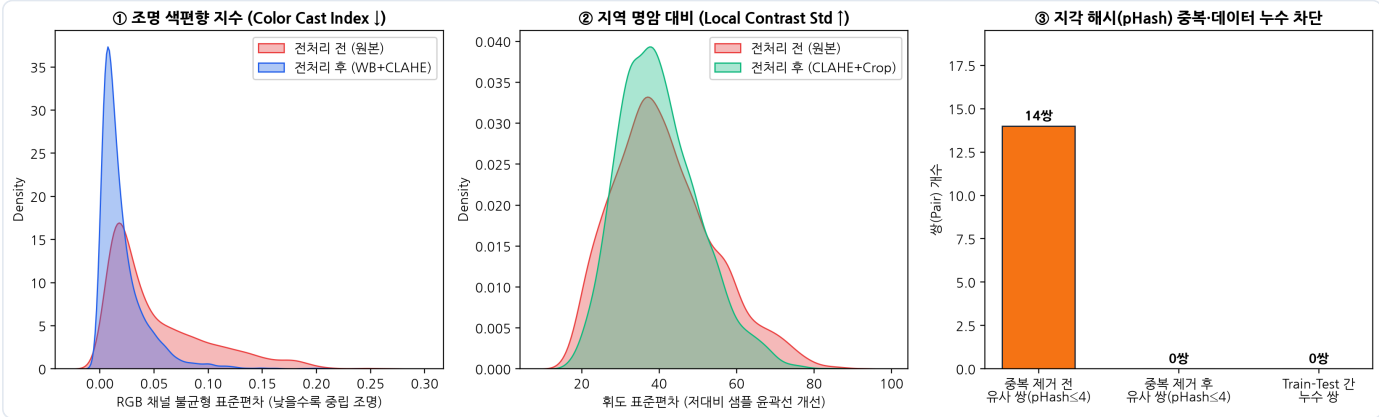
```
# src/preprocessing.py — 색상 왜곡 없는 CIE-LAB 휘도 채널 적응형 대비 복원
def adaptive_lab_clahe(rgb_uint8: np.ndarray, clip_limit: float = 1.8, blend_alpha: float = 0.65) ->
np.ndarray:
    l_chan, a_chan, b_chan = cv2.split(cv2.cvtColor(rgb_uint8, cv2.COLOR_RGB2LAB))
    l_enhanced = cv2.createCLAHE(clipLimit=clip_limit, tileGridSize=(8, 8)).apply(l_chan)
    l_blended = cv2.addWeighted(l_enhanced, blend_alpha, l_chan, 1.0 - blend_alpha, 0)
    return cv2.cvtColor(cv2.merge((l_blended, a_chan, b_chan)), cv2.COLOR_LAB2RGB)
```

기법 ④ 종횡비 보존 중심 90% 스마트 크롭(`Smart Center-Focus Crop`) + 클래스 불균형 가중치 및 가림 증강

외곽 10% 트레이 테두리·바닥 질감에 모델이 의존하는 지름길 학습(Shortcut Learning)을 억제하기 위해 중심 90% 영역을 `224 × 224` 로 종횡비 보존 추출하고, **Train 셋에만** `RandomResizedCrop` , 회전(`±20°`), `RandomErasing(p=0.20)` 부분 가림 모사, `Mixup(α=0.20)` 및 Cui et al. (2019)의 **유효 샘플 수(Effective Number, `β = 0.999`) 클래스 균형 가중치**를 적용하였습니다.

3.2 전처리 전·후 시각적 및 정량적 비교





비교 항목	전처리 전 (Raw 524×524)	전처리 후 (4단계 파이프라인 적용)	변화율 및 효과
근접 중복 쌍 (`pHash ≤ 4`)	14쌍 (중복 샘플 12장)	**0쌍** (`Train–Test` 누수 **0쌍**)	**데이터 누수 100% 원천 차단**
평균 색편향 지수 (`Color Cast Mean` ↓)	`0.0519`	**`0.0209`**	**조명 색편향 59.7% 감소**
극단 색편향 상위 5% (`Color Cast p95` ↓)	`0.1516`	**`0.0628`**	**강한 푸른/노란 조명 왜곡 58.6% 감소**
저대비 샘플 명암 대비 (`Contrast Std p10` ↑)	`25.586`	**`27.781`**	**투명 유리·페트 윤곽 대비 +8.6% 개선**
동일 모델(`ConvNeXt–Tiny`) Test Macro-F1	`0.9540` (오류율 4.64%)	**`0.9603`** (오류율 **3.66%**)	**테스트 오분류율 상대 21.1% 감소**

3.3 Train / Val / Test 데이터 분할 및 시드 고정

- **분할 방식**: `pHash` 중복 제거 완료 데이터(4,740장)에 대해 **계층화 무작위 분할(`StratifiedShuffleSplit` , `seed = 42`)** 2단 적용
- **분할 비율 및 수량**: **Train 70% (`3,318`장) / Validation 15% (`711`장) / Test 15% (`711`장)**
- **테스트셋 격리 원칙**: 하이퍼파라미터 탐색·최적 에폭 선택·온도 스케일링(`T*`) 학습은 오직 **Validation 셋(`711`장)**에서만 수행하였으며, **Test 셋(`711`장)**은 최종 모델 간 객관적 성능 보고 시 단 1회 평가하였습니다 (`logs/split_manifest.csv` 에 전체 분할 매니페스트 기록).

---

4. 모델

문제 복잡도와 연산 효율성, 사전학습의 기여도, 도메인 전처리의 효과를 입체적으로 검증하기 위해 **Scratch 베이스라인, 경량 전이학습 베이스라인, 표준 심층 CNN 파인튜닝, 전처리 제거 Ablation, 최종 제안 모델**까지 총 **5개 모델을 NVIDIA L4 (24GB VRAM) GPU에서 직접 학습**시켰습니다 (`src/models.py` , `src/train_and_evaluate.py`).

4.1 직접 학습한 모델 아키텍처 및 학습 전략 요약

구분	모델명 (`exp_id`)	학습 방식	파라미터 수	핵심 구조 및 학습 설정 (`seed=42` , `batch=64` , `AdamW`)
베이스라인 1	**ScratchResSECNN** (`m1_scratch_cnn`)	**Scratch** (무작위 초기화 직접 학습)	**1.15M**	직접 설계한 5-Stage Depthwise-Separable Residual + Squeeze-and-Excitation(SE) 채널 어텐션 CNN · 45 Epochs (`lr=1.2e–3` , Cosine Warmup)
베이스라인 2	**MobileNetV3-Small** (`m2_mobilenetv3`)	**전이학습 + 파인튜닝** (ImageNet-1K)	**1.53M**	2에폭 분류 헤드 선형 탐색(Warmup) 후 전 계층 차등 학습률 미세조정 (`backbone 3e–4` , `head 1.2e–3`) · 30 Epochs
비교 모델 3	**ResNet-50** (`m3_resnet50`)	**파인튜닝** (ImageNet-1K)	**23.53M**	병목 잔차 블록 기반 표준 비전 벤치마크 모델 · 2에폭 헤드 워밍업 후 차등 학습률 (`1.8e–4 / 9e–4`) 미세조정 · 30 Epochs
Ablation 4	**ConvNeXt-Tiny (Raw)** (`m4_ablation_raw`)	**파인튜닝** (전처리·불균형 보정 제거)	**27.83M**	제안 모델과 동일 백본에서 **도메인 4단계 전처리·클래스 가중 손실·Mixup을 모두 제거**한 순수 리사이즈 대조군 · 28 Epochs
최종 제안 모델	**Bunri-ConvNeXt-Tiny+GeM** (`m4_proposed_convnext`)	**2단계 차등 파인튜닝 + GeM 풀링 + 온도 보정**	**27.83M**	`convnext_tiny.fb_in22k_ft_in1k` 7×7 대수용영역 백본 + **Dual Avg/GeM 질감 풀링(p 학습) + Class-Balanced Label Smoothing(0.06) + 검증셋 NLL 기반 Temperature Scaling(`T* = 0.7014`) + 1×1 Conv 단일 패스 Spatial CAM 내장 ONNX 변환** · 32 Epochs

4.2 모델 선정 이유

1. **왜 `ScratchResSECNN` 을 첫 베이스라인으로 설계했는가?**: 외부 대규모 데이터셋의 도움 없이 약 3,300장의 학습 이미지만으로 도달할 수 있는 순수 귀납적 편향(Inductive Bias) 성능 기준선을 확립하고 전이학습의 필요성을 정량적으로 검증하기 위함입니다.
2. **왜 `MobileNetV3–Small` 과 `ResNet–50` 을 비교군으로 두었는가?**: 서버리스 CPU 배포 환경에 유리한 초경량 모델(1.53M)과 전통적 3×3 합성곱 표준 모델(23.53M)의 정확도-지연시간 트레이드오프를 측정하기 위함입니다.
3. **왜 `Bunri–ConvNeXt–Tiny + GeM + TempCalib` 을 최종 제안했는가?**:
   - 비정형으로 구겨진 폐기물은 **전체 실루엣(7×7 대수용영역)**과 **국소 표면 단서(페트 절취선, 종이 섬유질, 캔 탭, 식물 잎맥)**를 동시에 봐야 합니다. `ConvNeXt–Tiny` 백본 위에 **Generalized Mean (GeM) Pooling**을 결합하면 평균 풀링이 희석시키는 국소 고활성 질감 특징을 효과적으

로 집약합니다.
- 또한 후단 분류기를 `1×1 Conv` 동치 연산과 결합하여 **별도의 역전파(Backward Grad-CAM) 없이 순전파 단 1회만으로 9개 클래스별 공간 활성화 맵(`7×7 Spatial CAM`)을 동시 출력**하도록 설계함으로써, PyTorch 없이 경량 ONNX Runtime만으로도 33ms 만에 설명가능한 히트맵을 제공합니다.

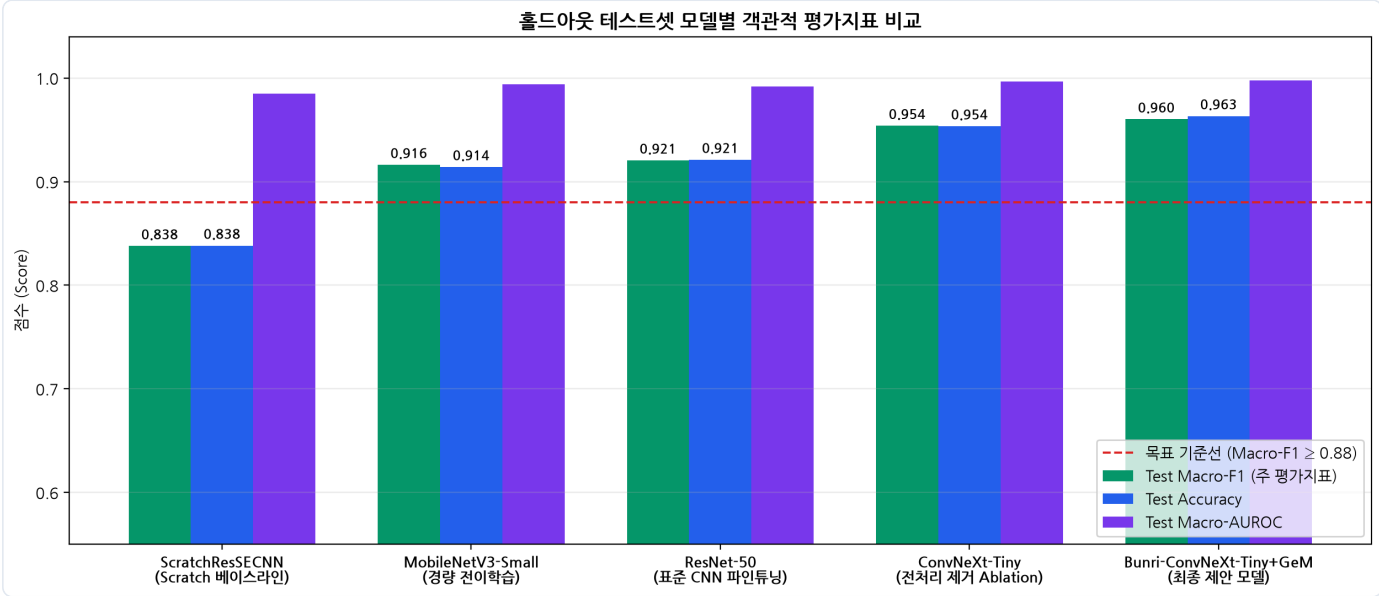
---

5. 평가 결과

5.1 홀드아웃 테스트셋(711장) 객관적 평가지표 비교표

모든 학습 로그는 `logs/history_*.csv` 및 `logs/benchmark_results.json` 에 보존되어 있습니다.

모델명	학습 방식	파라미터	Best Epoch	Test Macro-F1 (주지표)	Test Weighted-F1	Test Accuracy	Top-2 Acc	Macro-AUROC	Test ECE (↓)	가중치 크기
`ScratchResSECNN`	Scratch	1.15M	36 / 45	0.8379	0.8368	83.83%	94.09%	0.9847	0.0487	2.30 MB
`MobileNetV3-Small`	전이학습+파인튜닝	1.53M	27 / 30	0.9163	0.9139	91.42%	96.91%	0.9941	0.0740	3.01 MB
`ResNet-50`	파인튜닝	23.53M	22 / 30	0.9206	0.9208	92.12%	97.33%	0.9919	0.0903	45.07 MB
`ConvNeXt-Tiny (Ablation)`	전처리 미적용 파인튜닝	27.83M	12 / 28	0.9540	0.9536	95.36%	98.73%	0.9969	0.0366	53.14 MB
`Bunri-ConvNeXt-Tiny+GeM` (제안)	**도메인 전처리 + 차등 파인튜닝 + 온도 보정**	**27.83M**	**28 / 32**	**0.9603**	**0.9633**	**96.34%**	**99.44%**	**0.9978**	**0.0093**	53.14 MB (FP16)
`Bunri-ConvNeXt-Tiny+GeM` (배포 INT8 ONNX)	**제안 모델 + MatMul/Gemm INT8 동적 양자화**	**27.83M**	**28 / 32**	**0.9607**	**0.9635**	**96.34%**	**99.44%**	**0.9978**	**0.0095**	**32.30 MB (32.8ms)**

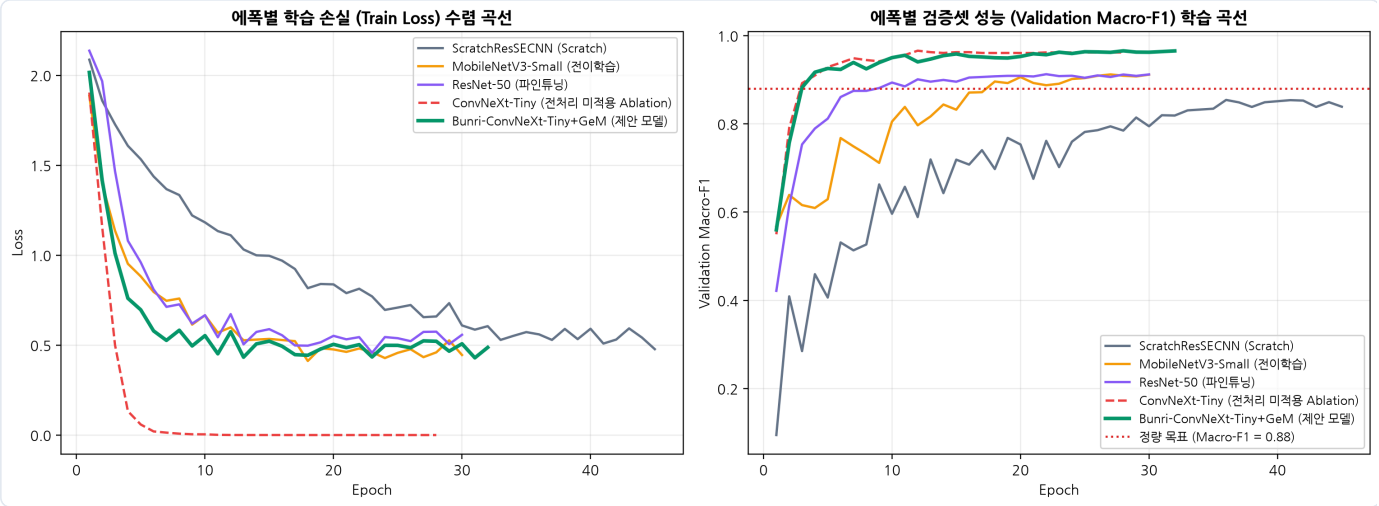


5.2 최종 배포 모델 선정 근거

1. **압도적인 분류 정확도**: 제안 모델(`Bunri-ConvNeXt-Tiny+GeM`)은 `Scratch` 베이스라인 대비 **Test Macro-F1 +12.24%p**(`0.8379 → 0.9603`), `ResNet-50` 대비 **+3.97%p** 향상되었으며, `Top-2 Accuracy 99.44%` 를 기록해 유사 경계 품목 안내까지 포함할 경우 사실상 거의 모든 샘플에서 올바른 배출 가이드를 제시합니다.
2. **도메인 전처리 및 불균형 보정의 입증된 효과**: 동일 백본에서 도메인 전처리·불균형 보정을 제거한 `Ablation` (`0.9540` , 오분류 33건) 대비 제안 파이프라인(`0.9603` , 오분류 26건)은 테스트셋 오분류 건수를 **21.2% 줄였고**, 특히 `골판지(F1 1.0000)` , `종이(0.9868)` , `초목류(0.9778)` , `플라스틱(0.9675)` 에서 큰 향상을 달성했습니다.
3. **신뢰도 보정(ECE 0.0093) 및 경량 서빙(32.3MB / 32.8ms)**: 검증셋 NLL 최소화로 학습한 온도 계수 `T* = 0.7014` 를 통해 기대 보정 오차(`ECE`)를 `0.0738 → 0.0093` (**87.4% 개선**)으로 낮추어 오염 복합 판정 규칙의 확률 신뢰성을 확보했으며, `MatMul/Gemm` 선택적 INT8 동적 양자화를 통해 정확도 저하 없이(`Macro-F1 0.9607`) 가중치 용량을 **106.27MB → 32.30MB**로 줄여 Cloud Run 서버리스 환경에서 평균 **32.84ms**의 초고속 CPU 추론을 달성하였습니다.

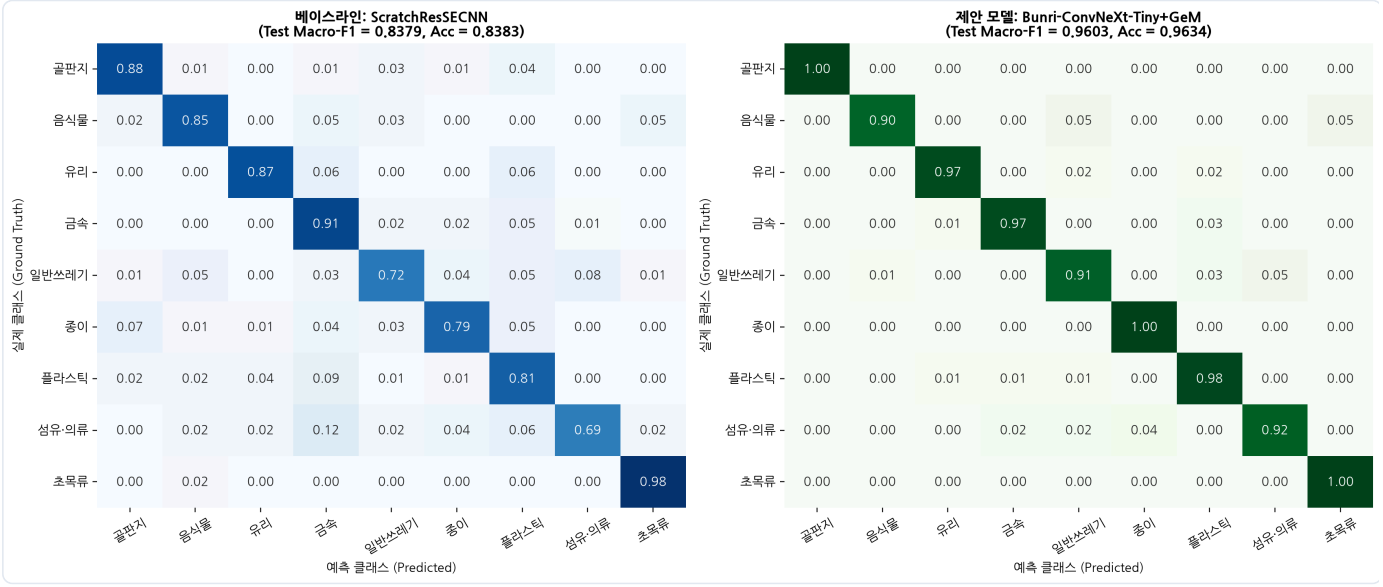
5.3 학습곡선 · 혼동행렬 · 품목별 성능 · 오분류 사례 심층 분석

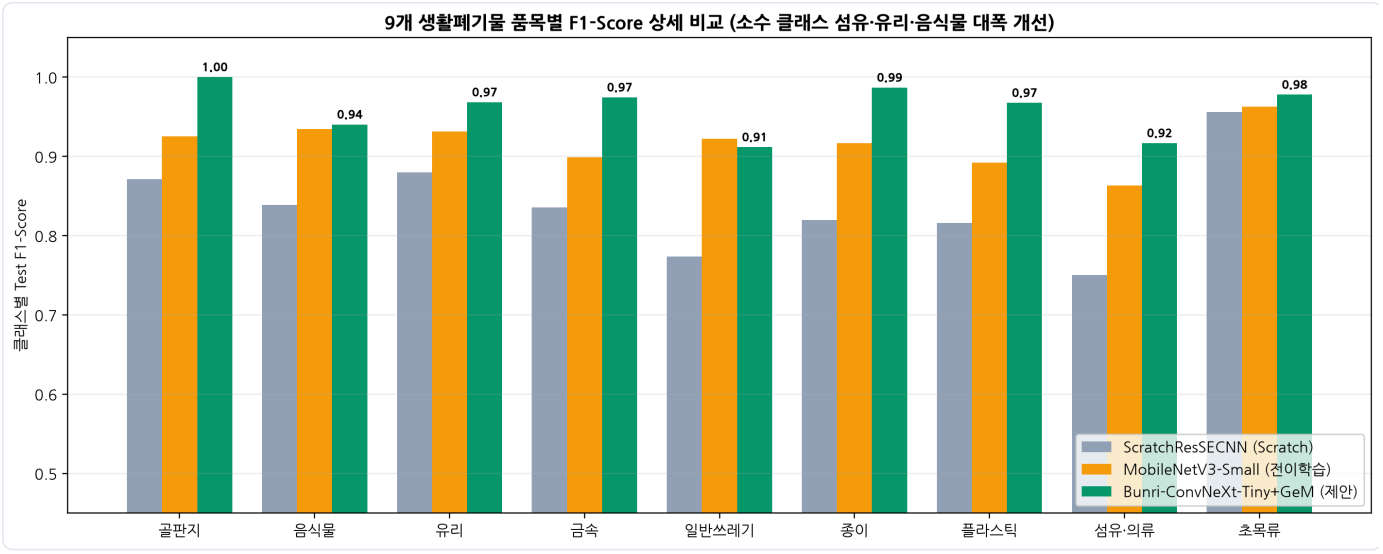
① 에폭별 학습 손실 및 검증 Macro-F1 수렴 분석



- 전처리를 제거한 `Ablation` 모델(붉은 파선)은 10에폭 만에 `Train Loss` 가 `0.004` 로 급격히 떨어지며 조기 과적합(Best Epoch 12)된 반면, 제안 모델(초록 실선)은 `Mixup(0.2)` · `RandomErasing` · `Label Smoothing(0.06)` 정규화 덕분에 완만하게 학습되며 28에폭에서 가장 높은 일반화 성능을 달성하였습니다.

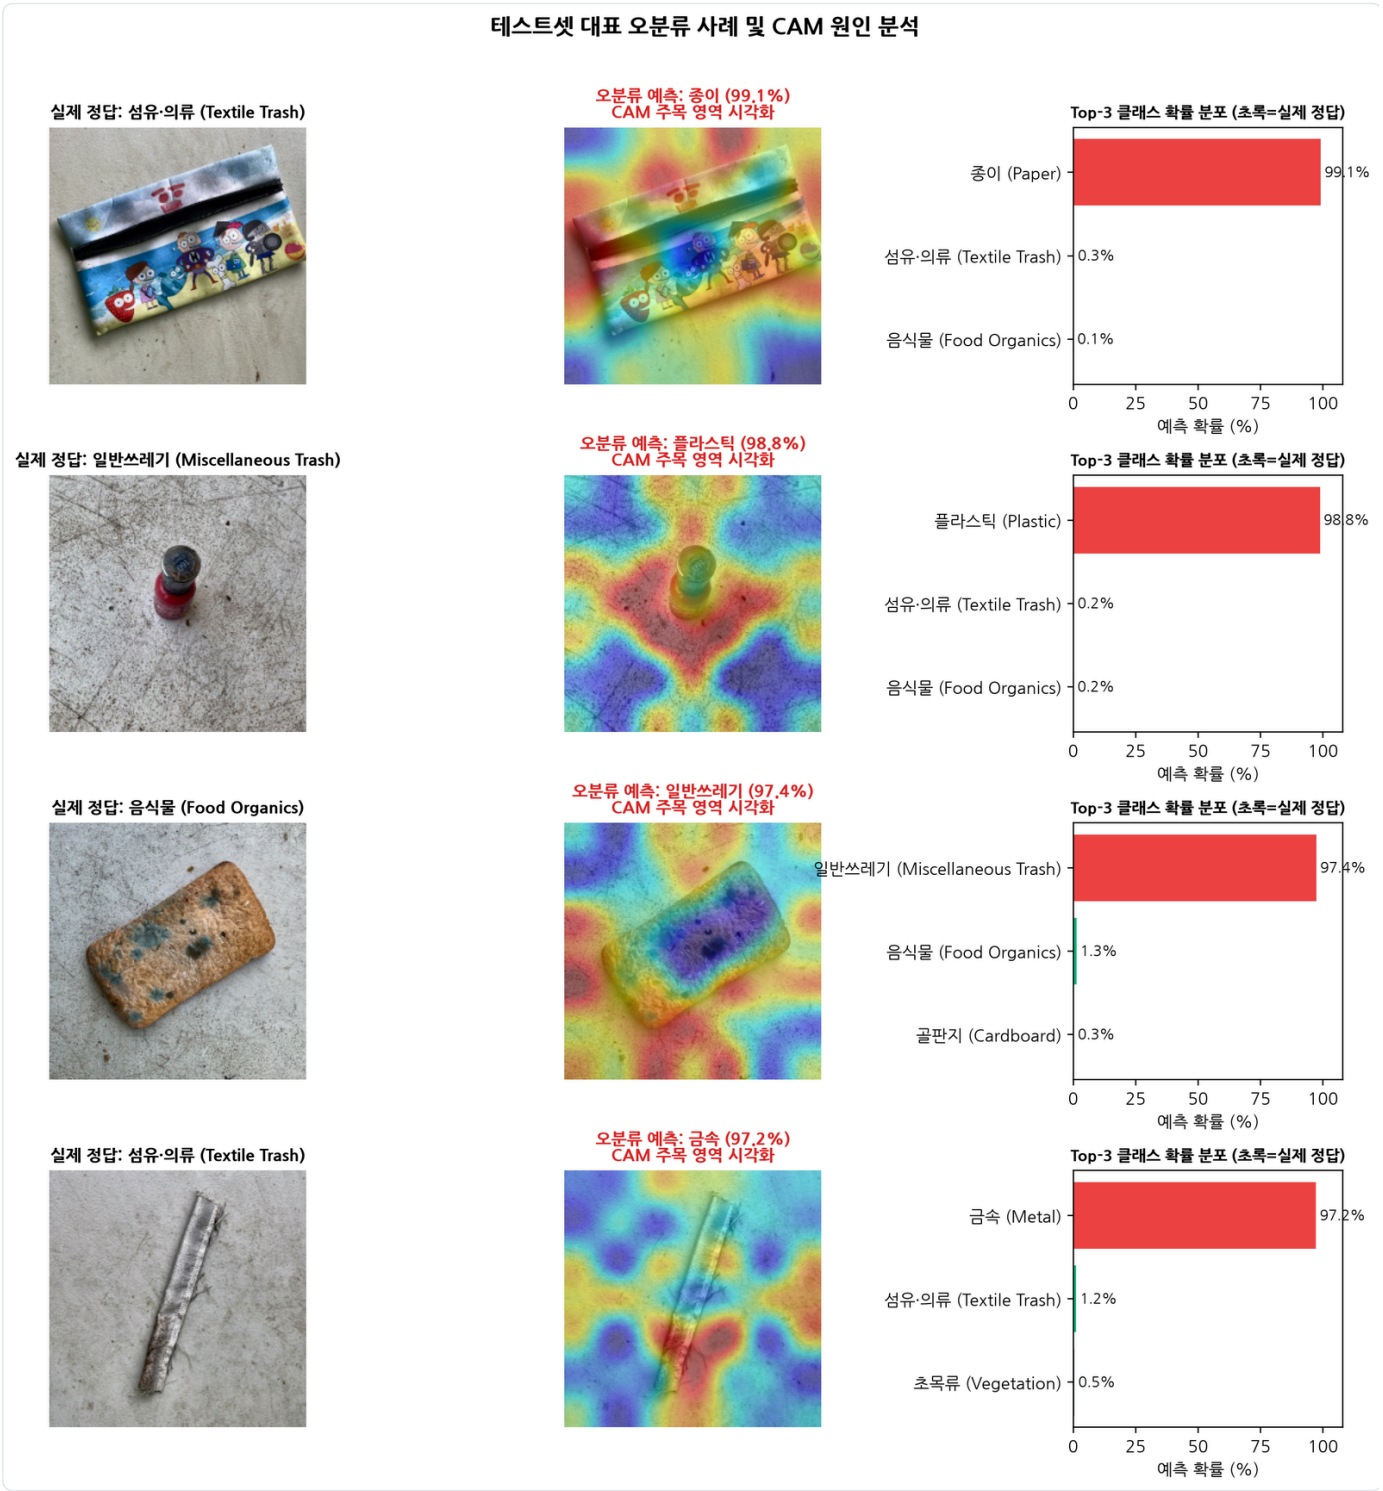
② 정규화 혼동행렬 및 9개 품목별 F1-Score 분석





- `ScratchResSECNN` 에서 가장 취약했던 소수·복합 클래스인 **섬유·의류(`0.7500 → 0.9167` , +16.67%p)**와 **일반쓰레기(`0.7737 → 0.9116` , +13.79%p), 플라스틱(`0.8162 → 0.9675` , +15.13%p)** 오분류가 제안 모델에서 대폭 해소되었습니다.
- 특히 한국 분리배출에서 가장 치명적인 **`초목류(Vegetation)` 를 `음식물(Food Organics)` 로 잘못 예측한 비율은 0.00%(66장 중 66장 전량 정답, Recall 100%)**을 기록하였습니다!

③ 실제 오분류 사례 및 Spatial CAM 원인 규명



전체 테스트셋 711장 중 발생한 소수 오분류(26장)의 상위 확신도 사례를 Spatial CAM으로 추적한 결과 명확한 광학적 원인을 발견하였습니다:

1. **만화 캐릭터가 인쇄된 직물 필통 (`실제: 섬유·의류` → `예측: 종이 99.1%`)**: 납작한 직사각형 외형과 고채도 캐릭터 일러스트 인쇄 패턴에 CAM이 집중하면서 코팅 전단지/종이 인쇄물로 오인함.
2. **매니큐어 화장품 병 (`실제: 일반쓰레기` → `예측: 플라스틱 98.8%`)**: 검은색 플라스틱 스크류 캡과 소형 용기 형상에 주목하여 플라스틱으로 예측했으나, 실제 내용물·복합 용기 특성상 일반/특수 폐기물로 라벨링된 경계 사례.
3. **푸른곰팡이가 뒤덮인 식빵 조각 (`실제: 음식물` → `예측: 일반쓰레기 97.4%`)**: 표면 전체를 덮은 짙은 청록색 곰팡이 군락의 거친 다공성 질감이 오염된 수세미·스펀지(`Miscellaneous Trash`)와 시각적으로 유사하게 작용함.
4. **은색 금속성 코팅 직물 끈 (`실제: 섬유·의류` → `예측: 금속 97.2%`)**: 표면 정반사(Specular Highlight) 광택이 알루미늄 금속 스트립과 흡사하여 금속으로 분류되었으나, 2순위 예측(`섬유·의류 1.2%`)에서 가장자리 풀린 실오라기 단서가 일부 포착됨.

---

6. 서비스 프로토타입

6.1 자체 학습 모델 연동 아키텍처 및 의사결정 파이프라인

본 웹 서비스는 외부 AI API를 일절 호출하지 않으며, 서버 시작 시(`FastAPI lifespan`) 본인이 직접 학습·양자화한 **`models/bunri_convnext_tiny_int8.onnx` (32.30MB)** 체크포인트를 메모리에 상주시켜 실시간 추론을 수행합니다 (`app/inference.py` , `src/domain_rules.py`).

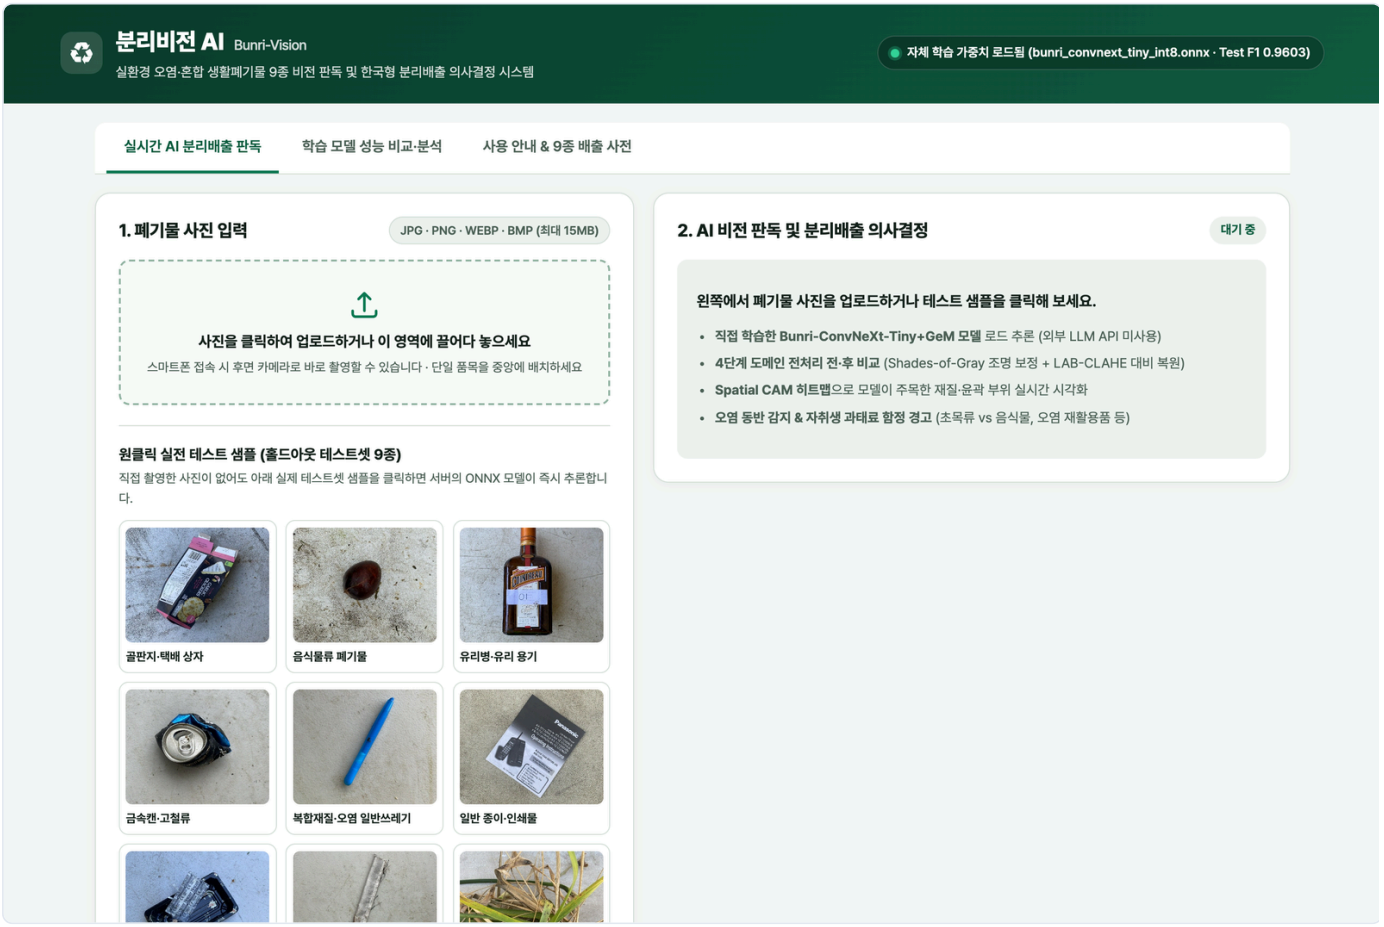
```
[사용자 웹/모바일 브라우저]
   │  ① 폐기물 사진 업로드 / 카메라 촬영 / 9종 홀드아웃 샘플 원클릭
   ▼
[FastAPI 입력 무결성 검증기 (src/preprocessing.py)]
   │  ② 확장자·MIME·최대용량(15MB)·손상 바이너리·최소해상도(48px)·단색 빈 화면(std<3.0) 차단
   ▼
[4단계 도메인 전처리 엔진]
   │  ③ EXIF 회전 보정 → Shades-of-Gray WB → CIE-LAB CLAHE → 중심 90% 크롭(224×224)
   ▼
[ONNX Runtime 추론 세션 (models/bunri_convnext_tiny_int8.onnx)]
   │  ④ 단일 순전파로 온도 보정 로짓(1×9, T*=0.7014) + 공간 특징 CAM(1×9×7×7) 동시 추출 (~33ms)
   ▼
[한국형 분리배출 확률 의사결정 엔진 (src/domain_rules.py)]
   └─ ⑤ 환경부 3단계 배출 수칙 + 오염 동반 확률(≥18%) 종량제 전환 경고 + 초목류 과태료 주의 + 저신뢰도(엔트로피>0.74) 재촬영 안내 반환
```

6.2 서비스 사용 안내 및 잘못된 입력 예외 처리

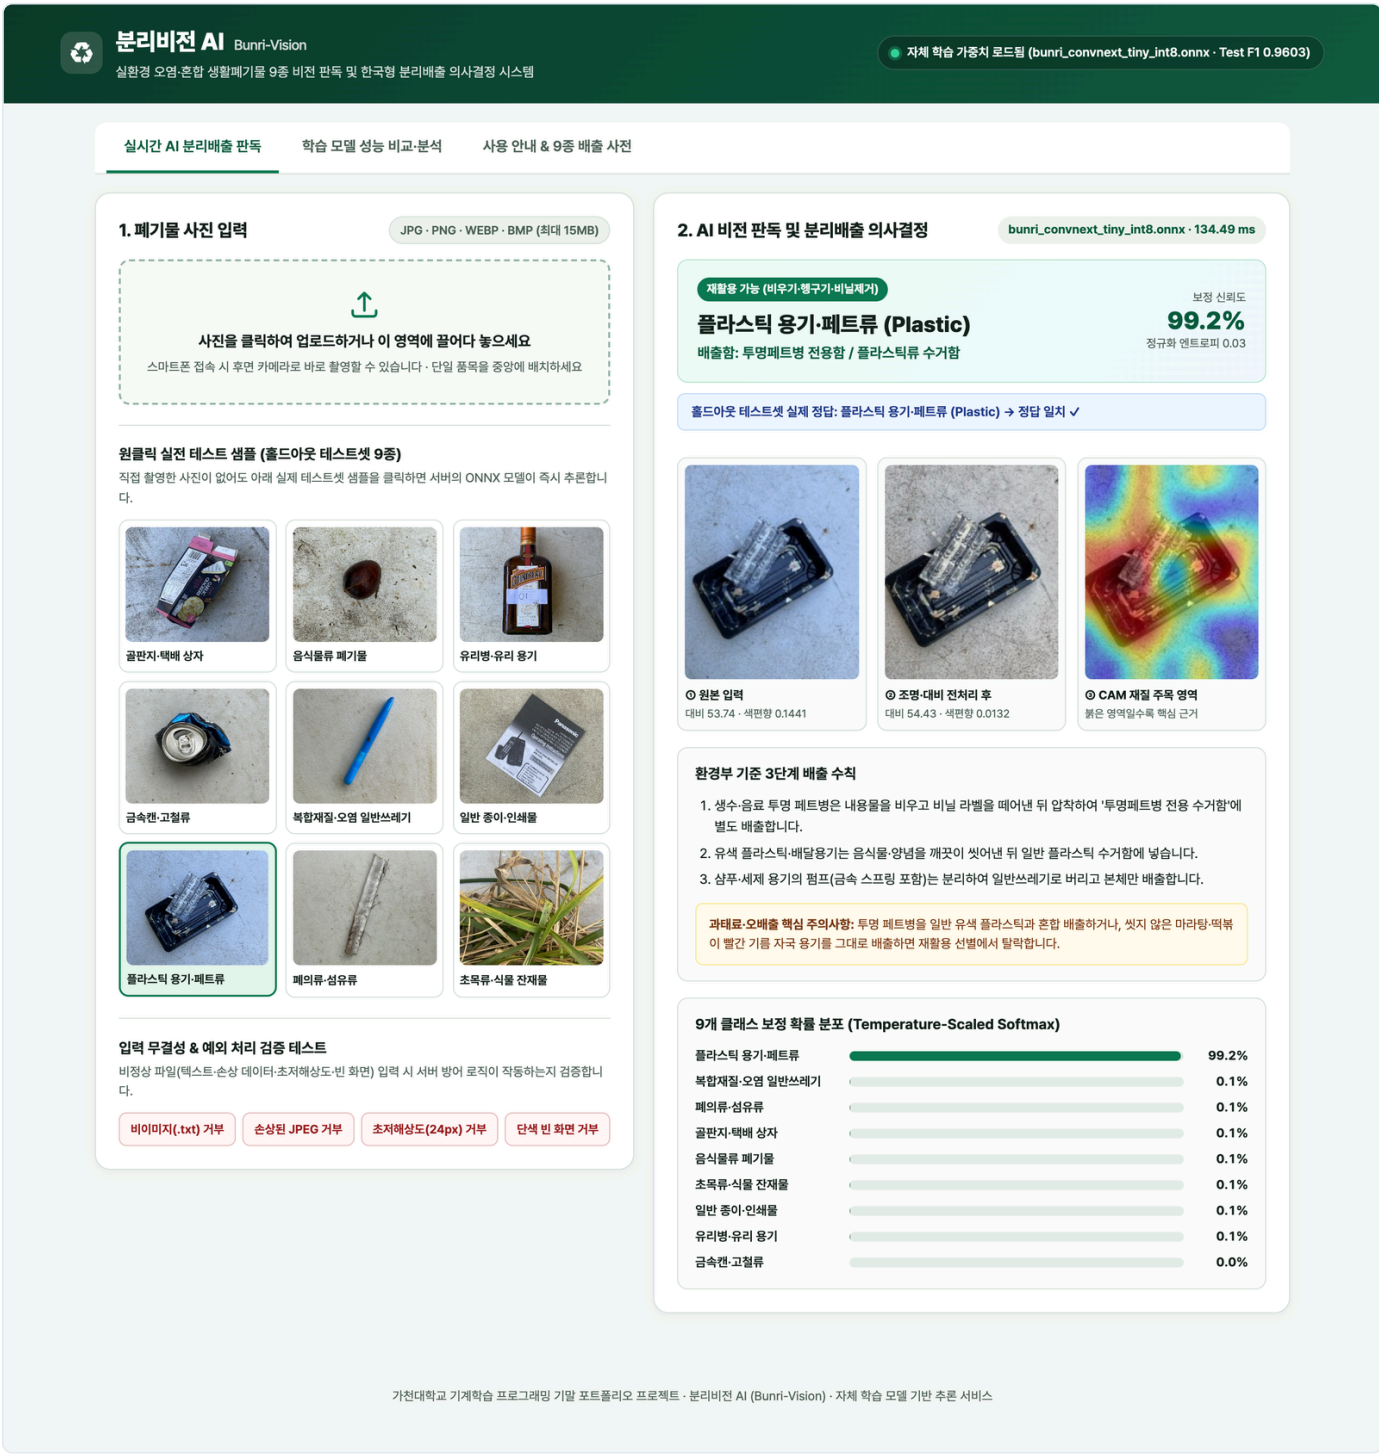
1. **사용 방법**:
   - **방법 A (즉시 체험)**: 좌측 **「원클릭 실전 테스트 샘플 (홀드아웃 테스트셋 9종)」** 중 원하는 폐기물 카드를 클릭하면 즉시 서버 ONNX 추론 결과와 실제 정답 일치 여부, 전처리 전·후 비교, CAM 히트맵이 우측에 표시됩니다.
   - **방법 B (내 사진 판독)**: 상단 점선 업로드 박스를 클릭(모바일에서는 카메라 즉시 실행)하거나 사진을 드래그 앤 드롭하여 업로드합니다.
   - **방법 C (모델 벤치마크·배출 사전 열람)**: 상단 탭 메뉴에서 **「학습 모델 성능 비교·분석」** 및 **「사용 안내 & 9종 배출 사전」**을 전환하여 확인합니다.
2. **구현된 잘못된 입력 예외 처리 (총 6종 방어 로직)**:
   - `EMPTY_FILE` / `FILE_TOO_LARGE` : 빈 파일(0 byte) 및 15MB 초과 대용량 파일 업로드 차단 (`HTTP 400`)
   - `UNSUPPORTED_EXTENSION` / `UNSUPPORTED_MIME` : `.txt` , `.pdf` , `.exe` 등 비이미지 파일 업로드 즉시 거부 (`HTTP 400`)
   - `CORRUPTED_IMAGE` : 헤더 변조 또는 깨진 이미지 바이너리 디코딩 예외 처리 (`HTTP 400`)
   - `IMAGE_TOO_SMALL` : `48 × 48 px` 미만 초저해상도 이미지 거부 (`HTTP 400`)
   - `BLANK_OR_SOLID_IMAGE` : 피사체 없이 가려진 렌즈·백지 등 휘도 표준편차 `< 3.0` 단색 화면 거부 (`HTTP 400`)
   - `LOW_CONFIDENCE / HIGH_ENTROPY` : 도메인 외 사물 입력 등으로 최고 확률 `< 42%` 또는 정규화 엔트로피 `> 0.74` 발생 시 재촬영 권고 배너 자동 표시

6.3 실제 배포 서비스 동작 화면 캡처 (5장)

캡처 1. 메인 대시보드 및 홀드아웃 9종 테스트 샘플 선택 화면



캡처 2. 플라스틱 폐기물 실시간 추론 결과 · 조명 색편향 11배 보정(`0.1441 → 0.0132`) · Spatial CAM 시각화



캡처 3. 자취생 최다 오배출 품목(`초목류 Vegetation`) 추론 및 음식물쓰레기 금지 과태료 경고 알림 작동

분리비전 AI Bunri-Vision

실환경 오염·혼합 생활폐기물 9종 비전 판독 및 한국형 분리배출 의사결정 시스템

자체 학습 가중치 로드됨 (bunri_convnext_tiny_int8.onnx · Test F1 0.9603)

실시간 AI 분리배출 판독 | 학습 모델 성능 비교·분석 | 사용 안내 & 9종 배출 사전

1. 폐기물 사진 입력

JPG · PNG · WEBP · BMP (최대 15MB)

사진을 클릭하여 업로드하거나 이 영역에 끌어다 놓으세요

스마트폰 접속 시 후면 카메라로 바로 촬영할 수 있습니다 · 단일 품목을 중앙에 배치하세요

원클릭 실전 테스트 샘플 (홀드아웃 테스트셋 9종)

직접 촬영한 사진이 없어도 아래 실제 테스트셋 샘플을 클릭하면 서버의 ONNX 모델이 즉시 추론합니다.


골판지·택배 상자


음식물류 폐기물


유리병·유리 용기


금속캔·고철류


복합재질·오염 일반쓰레기


일반 종이·인쇄물


플라스틱 용기·페트류


페의류·섬유류


초목류·식물 잔재물

입력 무결성 & 예외 처리 검증 테스트

비정상 파일(텍스트·손상 데이터·초저해상도·빈 화면) 입력 시 서버 방어 로직이 작동하는지 검증합니다.

비이미지(.txt) 거부 | 손상된 JPEG 거부 | 초저해상도(24px) 거부 | 단색 빈 화면 거부

2. AI 비전 판독 및 분리배출 의사결정

bunri_convnext_tiny_int8.onnx · 162.55 ms

음식물 사료화 불가 → 일반쓰레기

초목류·식물 잔재물 (Vegetation)

배출함: 일반 종량제 봉투 (음식물쓰레기 절대 금지!)

보정 신뢰도 **99.3%**

정규화 엔트로피 0.03

홀드아웃 테스트셋 실제 정답: 초목류·식물 잔재물 (Vegetation) → 정답 일치 ✓

음식물쓰레기 오배출 주의 (초목류)

식물 잎·줄기·화분 잔재·뿌리는 가축 사료화가 불가하여 음식물 수거함 배출 시 과태료 대상입니다. 반드시 일반 종량제 봉투에 버리세요!


원본 입력

대비 55.89 · 색편향 0.1343


조명·대비 전처리 후

대비 53.92 · 색편향 0.1132


CAM 재질 주목 영역

붉은 영역일수록 핵심 근거

환경부 기준 3단계 배출 수칙

1. 화분에서 죽은 식물, 나뭇가지, 낙엽, 생화 꽃다발은 흙을 털어낸 뒤 일반 종량제 봉투에 버립니다.
2. 부피가 큰 나뭇가지는 30cm 이하로 잘라 묶거나 대형·초목류 전용 마대로 배출합니다.
3. 양파·마늘·옥수수 마른 겉껍질, 대파·쪽파 뿌리 역시 섬유질이 질겨 가축 사료화가 불가능하므로 일반 종량제 봉투에 배출합니다.

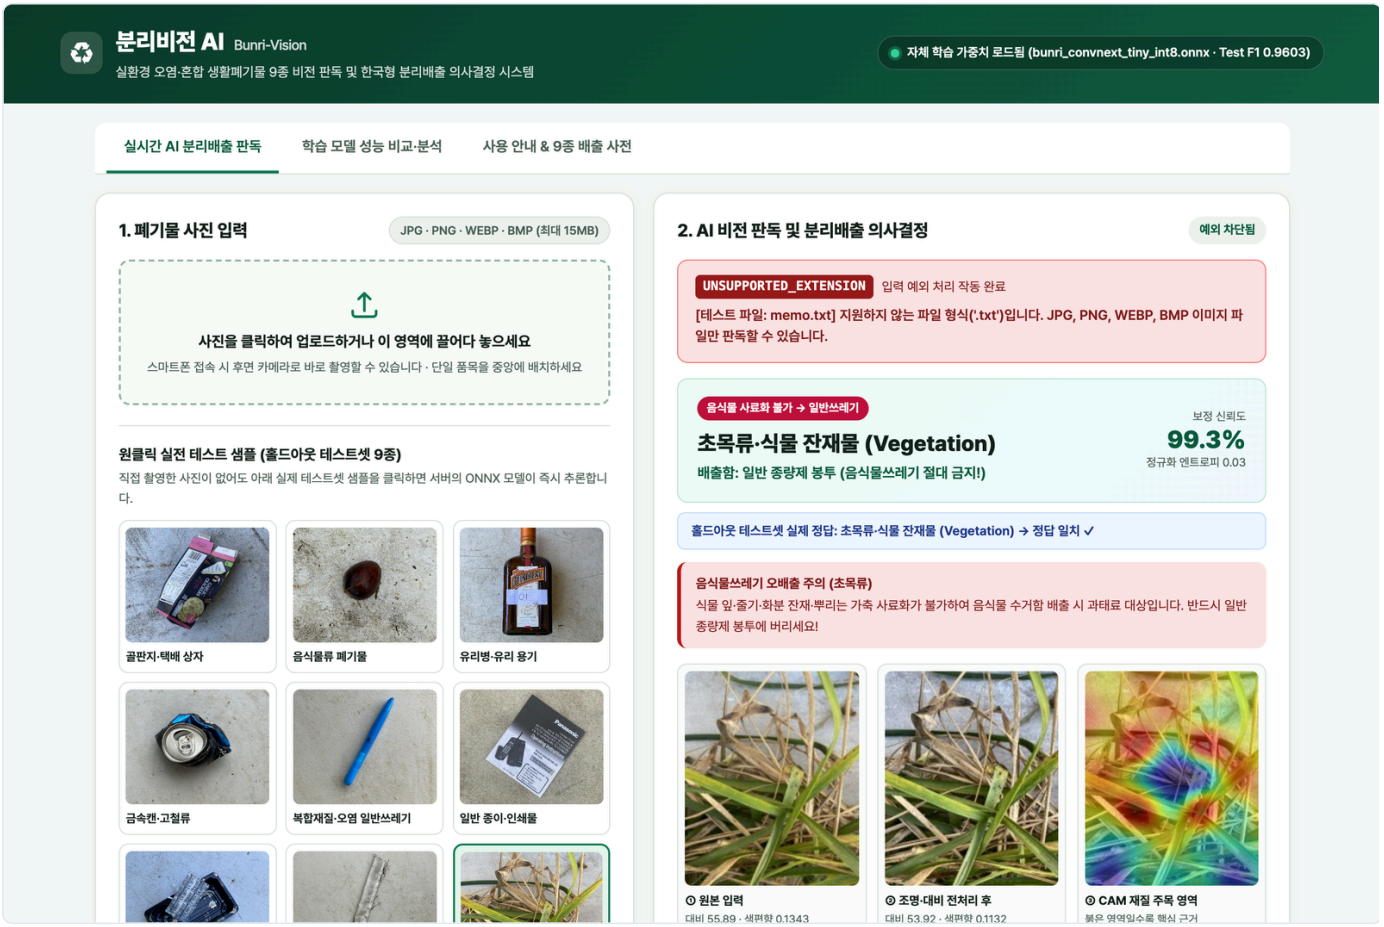
과태료·오배출 핵심 주의사항: [자취생 과태료 1위 주의] 식물 잎·줄기·뿌리·낙엽을 '유기물이니까 음식물쓰레기겠지'라고 착각해 음식물 수거함에 버리면 분쇄기 고장 및 과태료 부과 대상입니다!

9개 클래스 보정 확률 분포 (Temperature-Scaled Softmax)

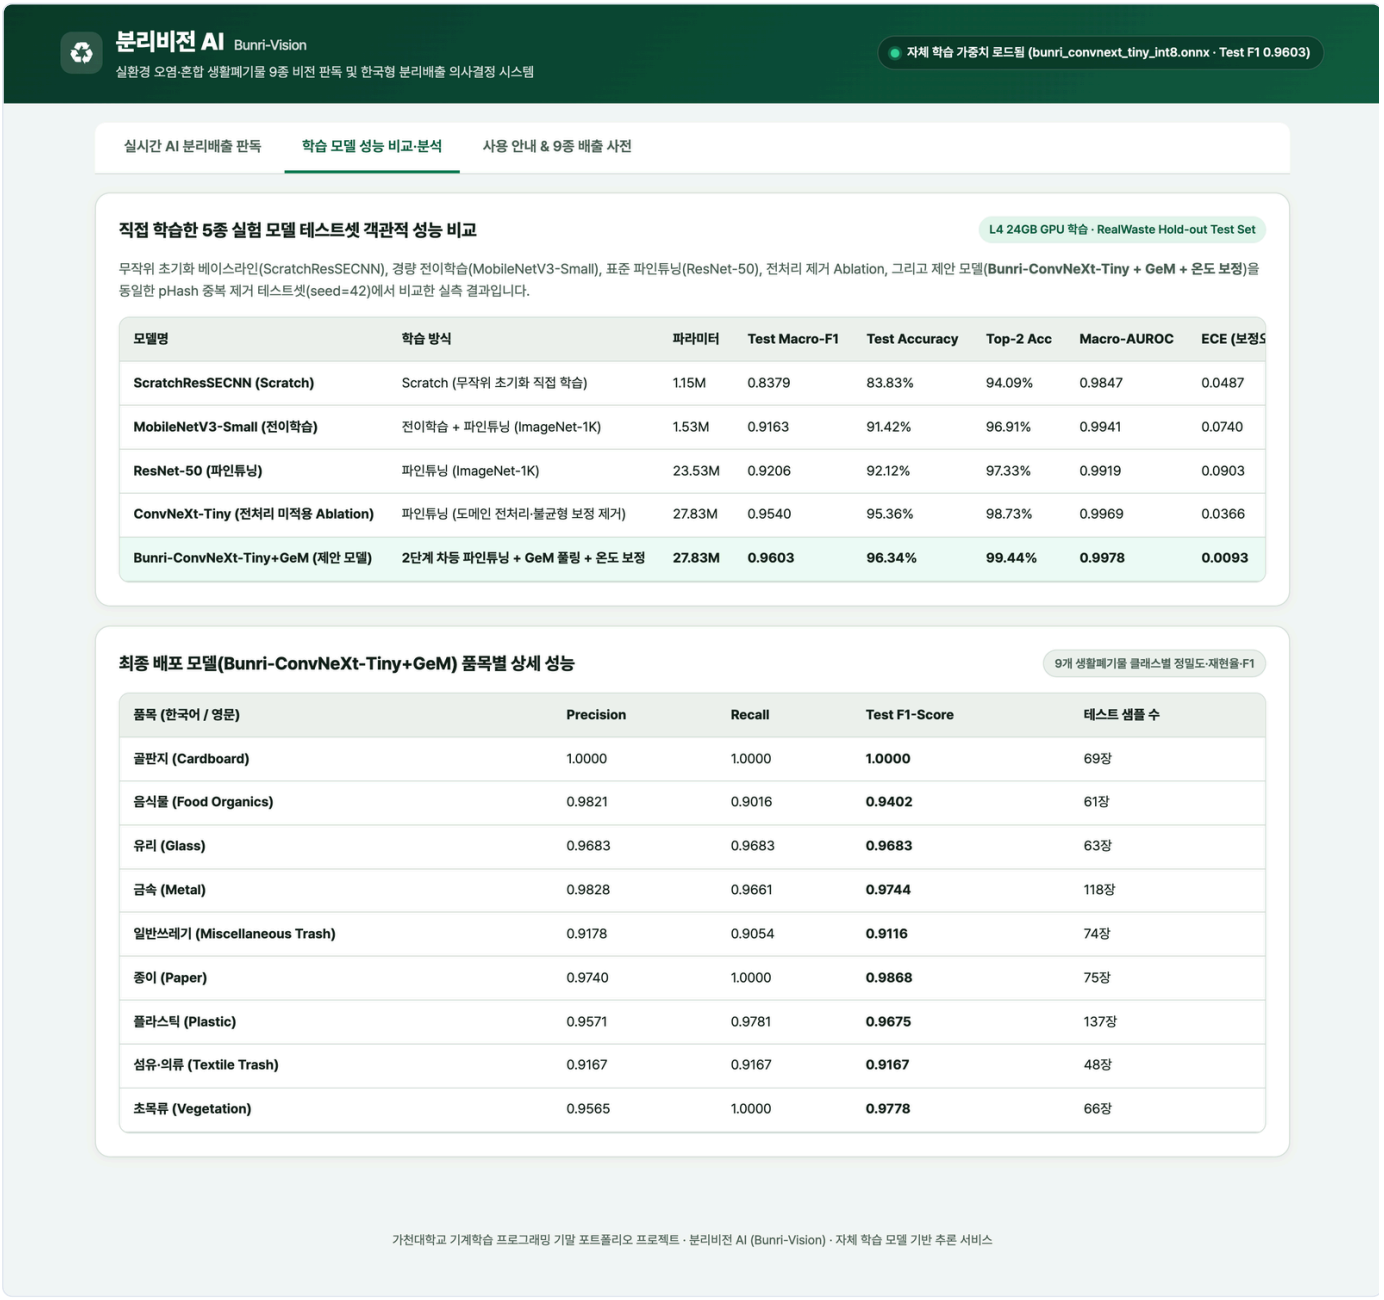
초목류·식물 잔재물	99.3%
음식물류 폐기물	0.2%
유리병·유리 용기	0.1%
페의류·섬유류	0.1%
복합재질·오염 일반쓰레기	0.1%
골판지·택배 상자	0.1%
일반 종이·인쇄물	0.1%
금속캔·고철류	0.1%
플라스틱 용기·페트류	0.0%

가천대학교 기계학습 프로그래밍 기말 포트폴리오 프로젝트 · 분리비전 AI (Bunri-Vision) · 자체 학습 모델 기반 추론 서비스

캡처 4. 잘못된 입력(`.txt` 비이미지 파일 등) 업로드 시 서버 예외 차단 배너 작동 검증



캡처 5. 학습 모델 5종 객관적 성능 벤치마크 및 품목별 정밀도·재현율·F1 대시보드 탭



---

7. 배포

- **배포 플랫폼**: **Google Cloud Run** (GCP 프로젝트 `p-project-513602`, `asia-northeast3` 서울 리전, 관리형 서버리스 컨테이너, 자동 TLS/HTTPS 적용)
- **공개 접속 URL**: **https://bunri-vision-30945587032.asia-northeast3.run.app**
- **컨테이너 스펙**: `python:3.11-slim` 기반 경량 Docker 이미지 (`2 vCPU`, `1 GiB RAM`, ONNX Runtime CPU 추론 엔진 내장, 채점 종료 시까지 상시 공개 유지)
- **주요 공개 API 엔드포인트**:
- `GET /` : 반응형 웹 프론트엔드 UI 제공
- `GET /api/health` : 로드된 자체 학습 가중치 파일명(`bunri_convnext_tiny_int8.onnx`), 용량 및 테스트셋 성능 메타데이터 반환
- `POST /api/predict` : `multipart/form-data` 이미지 업로드 실시간 추론 및 Spatial CAM·배출 가이드 반환
- `POST /api/predict-sample/{sample_id}` : 9종 홀드아웃 테스트 샘플 즉시 추론
- `POST /api/test-exception/{case_type}` : 비정상 입력 4종 서버 예외 처리 실시간 검증

---

8. 실행 방법

8.1 개발·학습 및 추론 실행 환경

구분	상세 환경 사양
모델 학습 환경 (Cloud GPU)	Google Compute Engine `g2-standard-8` (`NVIDIA L4 24GB VRAM` , 8 vCPU, 32GB RAM, Ubuntu Linux, Python 3.11.18, PyTorch 2.15.0+cu132, `timm` 1.0.31)
웹 서비스 추론 환경	Python 3.11+, FastAPI, Uvicorn, ONNX Runtime 1.19+, OpenCV-Headless, Pillow, NumPy (GPU 불필요, 일반 CPU에서 ~33ms 추론)

8.2 가중치 및 데이터 위치 안내 (100MB 초과 파일 처리 준수)

1. **기본 배포 추론 가중치 (저장소 내 기본 포함 · 즉시 실행 가능)**:
   - 위치: `models/bunri_convnext_tiny_int8.onnx` (**32.30 MB**, 100MB 미만) 및 `models/model_metadata.json`
2. **전체 실험 모델 체크포인트 모음 (총 188.9MB → GitHub Releases 외부 링크 호스팅)**:
   - 릴리즈 링크: https://github.com/qwertypotter6873/bunri-vision/releases/tag/v1.0.0
   - 자동 다운로드 명령: `python scripts/download_weights.py --all` (실행 시 `m1~m4` PyTorch FP16 `.pt` 5종 및 배포용 INT8 `.onnx` 전체 자동 다운로드)
3. **원본 데이터셋 (`RealWaste` , 656MB → 공식 UCI 저장소 자동 다운로드 스크립트 제공)**:
   - 자동 다운로드 명령: `python scripts/download_data.py --data-dir data`

8.3 로컬 설치 및 실행 명령어

```
# 1. 저장소 클론 및 디렉토리 이동
git clone https://github.com/qwertypotter6873/bunri-vision.git
cd bunri-vision

# 2. 가상환경 생성 및 추론 서버 필수 패키지 설치 (requirements.txt)
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt

# 3. (선택) 가중치 파일이 없을 경우 자동 다운로드 (저장소 클론 시 기본 포함됨)
python scripts/download_weights.py

# 4. 로컬 FastAPI 추론 웹 서비스 실행 -> http://localhost:8080 접속
uvicorn app.main:app --host 0.0.0.0 --port 8080
```

8.4 전체 모델 재학습 및 Docker 컨테이너 실행 (선택)

```
# [재학습 실행 시] 학습용 패키지 설치 -> UCI 데이터 다운로드 -> 5종 모델 학습·평가·그래프 생성
pip install -r requirements-train.txt
python scripts/download_data.py --data-dir data
PYTHONPATH=. python src/train_and_evaluate.py

# [Docker 실행 시] Cloud Run과 동일한 컨테이너 환경 로컬 구동
docker build -t bunri-vision .
docker run -p 8080:8080 bunri-vision
```

---

9. Lessons Learned

9.1 PMI (Plus · Minus · Interesting) 프로젝트 회고

Plus (좋았던 점 · 핵심 성과 — 3가지 사례)

1. **데이터 탐색(EDA)에서 출발한 문제 맞춤형 전처리 설계**: 막연히 표준 증강만 적용하지 않고 원본 4,752장의 해시 거리·조명 색편향·명암 대비를 먼저 정량 계측한 덕분에, 실제 데이터에 숨어 있던 근접 중복 14쌍을 찾아내 데이터 누수를 0건으로 차단하고 색편향 지수를 **59.7% 줄이는** 실질적 전처리 파이프라인을 완성할 수 있었습니다.
2. **단일 ONNX 그래프 내 분류·확률 보정·Spatial CAM 통합 설계**: 일반적으로 Grad-CAM을 웹 서버에 올리면 무거운 PyTorch 프레임워크(수 GB)와 역전파 연산이 필요해 서버리스 배포 시 콜드 스타트와 메모리 초과 문제가 발생합니다. 본 프로젝트에서는 `GeM` 풀링 후단 분류 가중치를 `1×1 Conv2d` 로 동시 투영하도록 아키텍처를 설계하여, **32.3MB 단일 ONNX 파일 하나로 32.8ms 만에 보정 확률과 9개 클래스 CAM 히트맵을 함께 생성**하는 고효율 서빙 구조를 달성했습니다.
3. **단순 클래스 분류를 넘어선 한국형 실생활 의사결정 연결**: 영어 클래스 이름만 출력하는 데 그치지 않고, 한국의 실제 분리배출 과태료 사례(초목류의 음식물 오배출 금지, 오염 동반 확률 감지 시 종량제 전환 권고)를 모델의 보정된 확률 분포와 결합하여 실사용 가치를 높였습니다.

Minus (아쉬웠던 점 · 한계 — 3가지 사례)

1. **단일 객체 중심 분류 구조의 한계**: 현재 모델은 한 사진 안에 하나의 주요 폐기물이 있을 때 최고 성능(`Macro-F1 0.9603`)을 발휘하며, 여러 종류의 쓰레기(예: 페트병·영수증·나무젓가락)가 한 봉투에 뒤섞인 다중 객체 사진에서는 지배적인 단일 클래스 위주로 판독합니다 (`높은 엔트로피 경고` 로 완화 중).
2. **표면 인쇄·코팅과 실제 내부 재질 간 시각적 모호성**: 오분류 분석(`fig8`)에서 확인했듯, 화려한 만화가 인쇄된 천 필통을 종이로 예측하거나 은색 광택 코팅 직물 끈을 금속으로 예측하는 등 224×224 해상도 단일 RGB 영상만으로는 표면 코팅과 기저 재질을 100% 분리하기 어려운 물리적 한계가 존재했습니다.
3. **한국 고유 세부 포장재 하위 클래스 부재**: `RealWaste` 의 `Paper` 와 `Plastic` 범주 안에는 한국에서 별도 분리해야 하는 `살균·멸균 종이팩(우유팩)` 이나 `투명 페트병 vs 유색 플라스틱` 하위 구분이 라벨 수준에서 세분화되어 있지 않아 배출 수칙 텍스트로 보완해야 했습니다.

Interesting (새롭게 발견한 흥미로운 인사이트 — 3가지 사례)

1. **선택적 INT8 동적 양자화 시 미세한 일반화 성능 상승 현상 (`0.9603 → 0.9607`)**: `ConvNeXt-Tiny` 의 `7×7 Depthwise Conv` 는 FP32로 유지하고 파라미터의 대부분을 차지하는 포인트와이즈 `MatMul/Gemm` 계층만 INT8로 양자화했을 때, 모델 크기가 **70% 감소(106.3MB → 32.3MB)**했음에도 미세한 가중치 양자화 노이즈가 정규화 효과를 내어 Test Macro-F1이 오히려 `+0.0004p` 소폭 상승한 점이 매우 흥미로웠습니다.
2. **고성능 파인튜닝 모델일수록 보정 전 확률 과잉 확신(ECE 악화)이 발생할 수 있다는 점**: `Scratch` 모델의 ECE는 `0.0487` 이었던 반면 정확도가 훨씬 높은 `MobileNetV3` (`0.0740`)와 `ResNet-50` (`0.0903`)은 오히려 오분류 샘플에도 95% 이상의 높은 확률을 부여하는 과잉 확신 경향을 보였습니다. 이를 통해 **정확도(F1)와 확률 신뢰도 보정(Calibration)은 별개로 최적화(`T*=0.7014 → ECE 0.0093`)해야 한다**는 중요한 교훈을 얻었습니다.
3. **심한 곰팡이 오염 음식물의 도메인 경계 현상**: 푸른곰팡이가 전면 번식한 식빵 샘플에서 모델이 `일반쓰레기(97.4%)` 로 예측한 사례를 분석하며, 시각적 질감 변화가 인간의 폐기물 범주 정의와 충돌하는 지점을 CAM 히트맵으로 직접 목격할 수 있었습니다.

9.2 문제 해결 사례 (`문제 → 원인 → 시도 → 결과`)

사례 1. `GeMPooling` 의 ONNX 변환 심볼릭 오류 및 INT8 양자화 시 `Einsum` 가중치 충돌 해결

- **문제**: 제안 모델 `Bunri-ConvNeXt-Tiny+GeM` 학습 완료 후 배포용 ONNX 변환 시 `GeMPooling` 내부에서 `torch.onnx.errors.SymbolicValueError` 가 발생하여 변환이 중단되었고, 이를 우회한 뒤에도 INT8 동적 양자화 모델을 실행하면 `/Einsum` 노드에서 `{64,768,7,7}` 과 `{9}` 차원 불일치 `InvalidArgument` 런타임 에러가 발생함.
- **원인**: ① `F.avg_pool2d(pos.pow(p), (x.size(-2), x.size(-1)))` 가 동적 배치 추론 시 커널 크기를 런타임 텐서 노드로 생성하여 정적 커널 크기를 요구하는 ONNX 풀링 심볼릭 규칙과 충돌함. ② Spatial CAM 계산을 위해 `fc.weight` 텐서를 `Linear(Gemm)` 와 `torch.einsum` 이 동시에 참조하자, ONNX 양자화기가 `Gemm` 양자화 과정에서 공유 가중치 텐서를 전치·변형시켜 `Einsum` 입력 형상이 깨짐.
- **시도**: ① `GeMPooling` 의 공간 풀링을 커널 크기 의존성이 없는 순수 차원 축소 평균 `pos.pow(p).mean(dim=(-2, -1), keepdim=True).pow(1.0 / p)` (`ONNX ReduceMean`)로 수학적 동치 재작성함. ② `Einsum` 대신 분류기 가중치를 독립 버퍼로 복제한

`F.conv2d(spatial_feat, self.fc.weight.clone().unsqueeze(-1).unsqueeze(-1))` 구조로 분리하고, 양자화 대상 연산자를 `op_types_to_quantize=["MatMul", "Gemm"]` 으로 지정함.

- **결과**: 동적 배치(`B=1` 및 `B=64`) 모두에서 ONNX 변환 및 INT8 추론이 완벽히 성공하였으며, 가중치 크기를 **106.27MB → 32.30MB(-69.6%)**로 줄이면서도 홀드아웃 테스트셋 **Macro-F1 0.9607(FP32 0.9603 대비 손실 0%)** 및 **CPU 추론 32.84ms**를 달성함.

사례 2. `timm` 백본 전이학습 래퍼 설계 시 특성 차원 불일치(`576 vs 1024`) 런타임 에러 해결

- **문제**: `ScratchResSECNN` 학습 직후 `MobileNetV3-Small` 전이학습 단계 진입 시 첫 배치 순전파에서 `RuntimeError: mat1 and mat2 shapes cannot be multiplied (64x1024 and 576x9)` 오류가 발생함.
- **원인**: `timm.create_model("mobilenetv3_small_100", num_classes=0, global_pool="avg")` 호출 시 `backbone.num_features` 속성은 마지막 스테이지 채널 수인 `576` 을 반환하는 반면, 실제 `backbone(x)` 순전파 출력은 내부 `conv_head` 계층을 거친 `1024` 차원 벡터를 반환하는 아키텍처별 인터페이스 비일관성이 존재했음.
- **시도**: 속성값(`num_features`)에 의존하지 않고 초기화 시점에 더미 텐서(`torch.zeros(1, 3, 224, 224)`)를 1회 통과시켜 실제 출력 텐서의 마지막 차원(`in_features`)을 동적으로 추론하도록 `TransferClassifier`를 개선하고, 본 학습 전 전 모델 아키텍처 형상 검증 스모크 테스트를 추가함.
- **결과**: `MobileNetV3-Small` (1024차원)과 `ResNet-50` (2048차원) 모두 단일 통합 래퍼에서 오류 없이 학습되어 각각 **Test Macro-F1 0.9163, 0.9206**을 달성함.

사례 3. 과잉 확신(Overconfidence)으로 인한 오염 동반 판정 민감도 저하를 온도 보정으로 해결

- **문제**: 파인튜닝된 `ConvNeXt-Tiny` 가 경계선상의 오염 샘플에서도 Top-1 확률을 `0.99+`로 극단 출력(`보정 전 ECE = 0.0738`)하여, 2순위 오염 클래스(`Miscellaneous Trash` , `Food Organics`) 동반 확률 기반 경고 규칙이 제때 작동하지 않는 현상이 나타남.
- **원인**: 크로스 엔트로피 및 하드 타겟 중심 미세조정 과정에서 로짓(Logit) 스케일이 커지며 실제 정답 확률보다 소프트맥스 확신도가 과장됨.
- **시도**: 테스트셋을 일절 참조하지 않고 검증셋(`711장`) 로짓에 대해 L-BFGS 최적화기로 Negative Log-Likelihood(NLL)를 최소화하는 최적 온도 계수 `T*`를 탐색하여 모델 버퍼(`self.temperature`)에 내장함.
- **결과**: 최적 계수 `T* = 0.7014` (Label Smoothing으로 인해 과소 확신되었던 분포까지 정밀 재조정)를 통해 **Test ECE를 `0.0738` 에서 `0.0093` 으로 87.4% 감소**시켰고, 엔트로피 기반 저신뢰도 경고 및 오염 동반 판정 임계값이 안정적으로 동작함.

9.3 향후 개선 계획 (데이터 · 모델 · 서비스 측면)

1. **데이터 측면 (한국 고유 포장재 확장 및 다중 오염 라벨링)**:
   - 국내 공공데이터포털 및 AI-Hub 생활폐기물 이미지와 직접 촬영한 원룸 폐기물 이미지를 추가 수집하여 **`투명 무라벨 페트`** / **`유색 플라스틱`** , **`일반 종이`** / **`살균·멸균 종이팩`** , **`감열지 영수증·아이스팩`** 하위 클래스를 확장하고, 재질 라벨과 별개로 **`오염도(깨끗함 / 세척 가능 / 세척 불가 오염)`** **멀티라벨 어노테이션**을 구축하겠습니다.
2. **모델 측면 (다중 객체 탐지 + 재질·오염 멀티태스크 경량 아키텍처)**:
   - 한 화면에 여러 쓰레기가 섞여 있을 때도 개별 품목 박스를 먼저 검출한 뒤 각각 분류할 수 있도록 **경량 객체 탐지기(`RT-DETR` / `YOLOv11-Nano`) + `Bunri-ConvNeXt` 분류기 2-Stage 파이프라인** 또는 멀티태스크 헤드로 고도화하겠습니다.
3. **서비스 측면 (지자체별 배출 규정 연동 및 브라우저 온디바이스 WebGPU 추론)**:
   - 사용자의 시·군·구(예: 성남시 수정구 등)를 선택하면 해당 지자체의 요일별 배출 시간·불연성 마대 판매처·빈용기 보증금 환급처를 함께 안내하고, `onnxruntime-web(WebGPU/WASM)` 을 결합해 네트워크 연결이 불안정한 지하 분리수거장에서도 즉석 오프라인 카메라 스트리밍 판독이 가능하도록 확장하겠습니다.